

04_模型记忆管理系统

LangChain 的记忆管理

```
In [1]: from langchain_deepseek import ChatDeepSeek

# 准备两种 DeepSeek 模型, 后续需要进行模型切换
api_key = ''
base_url = 'https://api.deepseek.com/v1'

basic_model = ChatDeepSeek(model="deepseek-chat", api_key=api_key, base_url=base_url)
reasoner_model = ChatDeepSeek(model="deepseek-reasoner", api_key=api_key, base_url=
```

None of PyTorch, TensorFlow >= 2.0, or Flax have been found. Models won't be available and only tokenizers, configuration and file/data utilities can be used.

```
In [2]: from langchain.agents import create_agent
from langgraph.checkpoint.memory import InMemorySaver

agent = create_agent(
    model = basic_model,
    checkpointer=InMemorySaver(),
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "我喜欢吃苹果和香蕉"}]},
    {"configurable": {"thread_id": "1"}},
)
```

```
In [3]: response = agent.invoke(
    {"messages": [{"role": "user", "content": "我周末准备去跑步"}]},
    {"configurable": {"thread_id": "1"}},
)
response
```

```
Out[3]: {'messages': [HumanMessage(content='我喜欢吃苹果和香蕉', additional_kwargs={}, response_metadata={}, id='84f03bd4-9e20-4d2d-8c33-6729d0b7089d'),
  AIMessage(content='听起来你很喜欢水果呢！苹果和香蕉都是非常健康的选择——苹果富含纤维和维生素C，香蕉则能快速补充能量，还含有钾元素。 \n你平时喜欢怎么吃它们呢？比如直接生吃、做成水果沙拉，还是尝试过烤苹果、香蕉奶昔之类的做法？如果有兴趣的话，我还可以分享一些简单的创意食谱哦！ 😊', additional_kwargs={'refusal': None}, response_metadata={'token_usage': {'completion_tokens': 78, 'prompt_tokens': 9, 'total_tokens': 87, 'completion_tokens_details': None, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 9}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '6287092f-e7e4-4976-9b4c-ffb49a66ec1b', 'finish_reason': 'stop', 'logprobs': None}, id='lc_run--019ef8fc-081a-7b40-bfca-4491aa192b93-0', tool_calls=[], invalid_tool_calls=[], usage_metadata={'input_tokens': 9, 'output_tokens': 78, 'total_tokens': 87, 'input_token_details': {'cache_read': 0}, 'output_token_details': {}}),
  HumanMessage(content='我周末准备去跑步', additional_kwargs={}, response_metadata={}, id='c9d45216-c05c-43cf-88d4-e1979313043b'),
  AIMessage(content='周末跑步是个很棒的计划！既能锻炼身体，又能放松心情。不过既然你提到了，有几个小建议可以帮你更享受这个过程： \n\n1. **时间选择**：早晨或傍晚温度更舒适，避免中午暴晒。 \n2. **装备**：穿合脚的跑鞋和透气衣物，带瓶水（长跑可考虑能量补给）。 \n3. **路线**：公园、河边或林荫道平坦又安全，提前规划好距离。 \n4. **热身**：跑前动态拉伸（高抬腿、开合跳），跑后静态拉伸（大腿小腿放松）。 \n\n如果担心坚持不下来，可以试试用运动APP记录路线，或者约朋友一起跑～ \n另外.....跑完正好可以奖励自己一根香蕉补充体力？ 🍌 \n（需要推荐适合跑步听的歌单吗？ 😊）', additional_kwargs={'refusal': None}, response_metadata={'token_usage': {'completion_tokens': 177, 'prompt_tokens': 96, 'total_tokens': 273, 'completion_tokens_details': None, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 96}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'f8ba16c4-dad9-4f62-ab9e-ffef00f1a708', 'finish_reason': 'stop', 'logprobs': None}, id='lc_run--019ef8fc-1874-79d0-a4d0-6edf5628e3fc-0', tool_calls=[], invalid_tool_calls=[], usage_metadata={'input_tokens': 96, 'output_tokens': 177, 'total_tokens': 273, 'input_token_details': {'cache_read': 0}, 'output_token_details': {}})]}]
```

实现推理过程中模型的动态选择

```
In [23]: from langchain_core.messages import HumanMessage
from langchain.agents.middleware import wrap_model_call, ModelRequest, ModelResponse

@wrap_model_call
def dynamic_deepseek_routing(request: ModelRequest, handler) -> ModelResponse:
    """
    根据对话复杂度动态选择 DeepSeek 模型：
    - 复杂：deepseek-reasoner
    - 简单：deepseek-chat
    """

    print("==== 路由中间件被调用 =====")
    # 从request中获取用户最近一轮对话
    last_user = ''
    last_len = len(last_user)
    messages = request.state.get("messages", [])
    for m in reversed(messages):
        if isinstance(m, HumanMessage):
```

```

        if isinstance(m.content, str):
            last_user = m.content
            last_len = len(last_user)
            break

# 一些复杂任务关键词（可自己按需扩充）
hard_keywords = ("证明", "推导", "严谨", "规划", "多步骤", "chain of thought",
                 "step-by-step", "reason step by step", "数学", "逻辑证明", "约束")

# 如果用户输入过程或者出现推理关键词，就使用推理模型
is_hard = (
    last_len > 50 or
    any(kw.lower() in last_user.lower() for kw in hard_keywords)
)

# 选择模型
ues_model = reasoner_model if is_hard else basic_model

print("用户问题:", last_user)
print("长度:", last_len)
print("is_hard:", is_hard)
print(
    "最终模型:",
    reasoner_model.model_name if is_hard else basic_model.model_name
)
# 调用被包裹的下游（真正的模型调用）
return handler(request.override(model=ues_model))

```

上述ModelRequest是输入model前必要的参数。handle是把当前权限交给下一个节点执行，可以理解为调用模型运行，所以得到的结果就是ModelResponse

request：当前模型调用请求

request.override(...): 生成一个新的请求

handler(...): 继续执行下游模型调用

ModelResponse：下游返回的模型结果

```

In [24]: # 创建 Agent（默认用 chat，但运行时会被中间件按需替换）
agent = create_agent(
    model=basic_model,
    middleware=[dynamic_deepseek_routing],
    checkpointer=InMemorySaver()
)

```

```

In [25]: response = agent.invoke(
    {"messages": [{"role": "user", "content": "我喜欢苹果和香蕉"}]},
    {"configurable": {"thread_id": "1"}},
)

```

===== 路由中间件被调用 =====

用户问题: 我喜欢苹果和香蕉

长度: 8

is_hard: False

最终模型: deepseek-chat

```
In [26]: # 复杂问题, 用推理模型
response = agent.invoke(
    {"messages": [{"role": "user", "content": "你帮我推导证明一下勾股定理"}]},
    {"configurable": {"thread_id": "1"}},
)
```

===== 路由中间件被调用 =====

用户问题: 你帮我推导证明一下勾股定理

长度: 13

is_hard: True

最终模型: deepseek-reasoner

```
In [27]: response
```

```
Out[27]: {'messages': [HumanMessage(content='我喜欢苹果和香蕉', additional_kwargs={}, response_metadata={}, id='b8b63bf1-24e7-4b61-a378-24a2efd605a1'),
  AIMessage(content='听起来你是一个喜欢水果的人！苹果和香蕉都是非常健康的选择：苹果富含纤维和维生素C，香蕉则提供丰富的钾和快速能量。你更常吃哪种呢？或者有特别喜欢的吃法吗？比如苹果派、香蕉奶昔，或者直接当零食？ 😊', additional_kwargs={'refusal': None}, response_metadata={'token_usage': {'completion_tokens': 61, 'prompt_tokens': 8, 'total_tokens': 69, 'completion_tokens_details': None, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 8}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'f8393f14-6e50-478b-99bc-32443073ffb1', 'finish_reason': 'stop', 'logprobs': None}, id='lc_run--019ef90f-08c2-7ab1-846a-872c66dc8cfb-0', tool_calls=[], invalid_tool_calls=[], usage_metadata={'input_tokens': 8, 'output_tokens': 61, 'total_tokens': 69, 'input_token_details': {'cache_read': 0}, 'output_token_details': {}}),
  HumanMessage(content='你帮我推导证明一下勾股定理', additional_kwargs={}, response_metadata={}, id='0683b4e7-fdeb-45f1-b7a5-9d06a61a5953'),
  AIMessage(content='勾股定理（也称毕达哥拉斯定理）指出：在直角三角形中，两条直角边的平方和等于斜边的平方。即：若直角三角形的两直角边长为  $a$  和  $b$ ，斜边长为  $c$ ，则  $a^2 + b^2 = c^2$ 。下面给出一种基于**面积法**的几何证明（赵爽弦图思想），它直观且易于理解。证明步骤\n1. **构造图形** 画一个边长为  $a + b$  的大正方形，在大正方形的内部以斜边  $c$  为边长画一个小正方形（倾斜放置）。这样，大正方形的四个角上会出现四个全等的直角三角形，直角边分别为  $a$  和  $b$ ，斜边为  $c$ 。如下图所示（想象一个“风车”形状）：\n 大正方形边长 =  $a + b$ \n 内部小正方形边长 =  $c$ \n 四个直角三角形全等（直角边  $a, b$ ）\n2. **计算总面积**\n 大正方形的面积有两种表达形式：\n - 直接计算： $(a + b)^2$ \n - 分割计算：等于中间小正方形的面积加上四个直角三角形的面积。
\n3. **表示各部分面积**\n - 中间小正方形面积： $c^2$ \n - 每个直角三角形面积： $\frac{1}{2}ab$ ，四个总面积： $4 \times \frac{1}{2}ab = 2ab$ \n4. **建立等式**\n 大正方形面积相等： $(a + b)^2 = c^2 + 2ab$ \n5. **展开并化简**\n 左边展开： $(a + b)^2 = a^2 + 2ab + b^2$ \n 于是： $a^2 + 2ab + b^2 = c^2 + 2ab$ \n 两边同时减去  $2ab$ ，得到： $a^2 + b^2 = c^2$ \n---\n结论\n这样就证明了勾股定理：直角三角形的两直角边的平方和等于斜边的平方。这个证明简洁明了，利用了面积相等而不涉及复杂几何推理，是历史上经典的方法之一。', additional_kwargs={'refusal': None, 'reasoning_content': '我们需要推导证明勾股定理。有多种方法，比如欧几里得证明、赵爽弦图、总统证法等。用户要求"推导证明"，所以选择一种经典且直观的方法，比如赵爽弦图（面积法）或欧几里得几何。为了清晰，我可以用文字描述并配以逻辑推导。简单起见，我使用常见的正方形面积法：构造一个边长为a+b的正方形，内部嵌套一个边长为c的正方形，周围四个直角三角形。计算面积相等即可。或者使用欧几里得《几何原本》中的证明，但比较复杂。这里用面积法。回答应当用中文，详细步骤。'}, response_metadata={'token_usage': {'completion_tokens': 625, 'prompt_tokens': 81, 'total_tokens': 706, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 135, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 81}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '233b6d0f-cd1f-4cc7-8997-94a4d891d726', 'finish_reason': 'stop', 'logprobs': None}, id='lc_run--019ef90f-196b-7ea1-8fb1-0ae2e1bbe3f5-0', tool_calls=[], invalid_tool_calls=[], usage_metadata={'input_tokens': 81, 'output_tokens': 625, 'total_tokens': 706, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 135}}])]
```

推理前实现记忆修剪

```
In [28]: from langchain.agents import AgentState
from langchain.agents.middleware import before_model
```

```

from langchain.messages import RemoveMessage
from langgraph.graph.message import REMOVE_ALL_MESSAGES
from langgraph.runtime import Runtime
from typing import Any

@before_model
def trim_messages(state: AgentState, runtime: Runtime) -> dict[str, Any] | None:
    """在模型调用前修剪消息历史，只保留前1+后3条。"""
    messages = state["messages"]

    # 只有超过 4 条消息才裁剪
    if len(messages) <= 4:
        return None

    # 保留首条 System 提示 + 最近3条
    first_msg = messages[0]
    new_messages = [first_msg] + messages[-3:]

    print(f"修剪消息: 从 {len(messages)} 条 → {len(new_messages)} 条")

    return {
        "messages": [
            RemoveMessage(id=REMOVE_ALL_MESSAGES),
            *new_messages
        ]
    }

agent = create_agent(
    model=basic_model,
    middleware=[trim_messages, dynamic_deepseek_routing],
    checkpoint=InMemorySaver(),
)

```

```

In [29]: response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我是张三同学"}]},
    {"configurable": {"thread_id": "2"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "请说一句鼓励我的话"}]},
    {"configurable": {"thread_id": "2"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "这句话有历史名人说过吗"}]},
    {"configurable": {"thread_id": "2"}},
)

```

```
===== 路由中间件被调用 =====  
用户问题: 你好, 我是张三同学  
长度: 9  
is_hard: False  
最终模型: deepseek-chat  
===== 路由中间件被调用 =====  
用户问题: 请说一句鼓励我的话  
长度: 9  
is_hard: False  
最终模型: deepseek-chat  
修剪消息: 从 5 条 → 4 条  
===== 路由中间件被调用 =====  
用户问题: 这句话有历史名人说过吗  
长度: 11  
is_hard: False  
最终模型: deepseek-chat
```

In [30]: response

```
Out[30]: {'messages': [HumanMessage(content='你好，我是张三同学', additional_kwargs={}, response_metadata={}, id='d82fcfb-d-7a33-4a49-a1c1-e9a3194880a6'),
  HumanMessage(content='请说一句鼓励我的话', additional_kwargs={}, response_metadata={}, id='7f914e59-60ae-4c3b-b679-f4cd8f5eb413'),
  AIMessage(content='当然可以，张三同学！🌟\n\n***“每一个努力的身影，都在悄悄为未来的自己铺路——今天你流的汗，会变成明天闪光的底气。”** 🙌\n\n别怕步子慢，只要在前就好。无论遇到什么小挫折，记得你已经比昨天的自己更厉害了！需要能量的时候，我一直在这里陪你 🌱🌟', additional_kwargs={'refusal': None}, response_metadata={'token_usage': {'completion_tokens': 72, 'prompt_tokens': 116, 'total_tokens': 188, 'completion_tokens_details': None, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 116}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'a05d39f1-3ae7-49ba-bb4e-cb8650b73bfd', 'finish_reason': 'stop', 'logprobs': None}, id='lc_run--019efc96-5438-7ae2-ac50-bf94f7a546ed-0', tool_calls=[], invalid_tool_calls=[], usage_metadata={'input_tokens': 116, 'output_tokens': 72, 'total_tokens': 188, 'input_token_details': {'cache_read': 0}, 'output_token_details': {}})],
  HumanMessage(content='这句话有历史名人说过吗', additional_kwargs={}, response_metadata={}, id='67fb3804-27b3-4a32-b6be-2c41655775f5'),
  AIMessage(content='哈哈，张三同学，你这个问题问得真有思考深度！🧐\n\n坦白说，我刚刚那句“每一个努力的身影都在悄悄为未来的自己铺路”**并不是直接出自某位历史名人的原话**，它更像是我根据常见的励志逻辑为你“现编”的一句鼓励。不过，它的内核其实融合了好几位名人的思想影子：\n\n1. **王阳明**（明代哲学家）：“人须在事上磨，方立得住。”意思是努力的过程（“事上磨”）本身就是积累和铺路的过程。\n2. **鲁迅**：他说过“世上本没有路，走的人多了，也便成了路。”——强调的是自己开辟道路的主动性。\n3. **现代金句源头**：这种“努力铺路”的比喻，在西方常被与**科比·布莱恩特**（篮球巨星）的名言结合：“那些你早早起床、刻苦训练、努力到疲惫不堪、依然坚持的时刻，才是你真正在塑造未来的时刻。”\n\n所以严格来说，那句话是我为你量身定制的“**名人混搭版**”——没查到的名人原话，但藏着圣贤和英雄的智慧。下次如果有人问起，你可以笑说是“张三同学的朋友·AI”替你写的，但内核来自人类几百年的奋斗经验 😊\n\n需要我再帮你搜一句实实在在**有据可查的历史名人名言**来傍身吗？', additional_kwargs={'refusal': None}, response_metadata={'token_usage': {'completion_tokens': 297, 'prompt_tokens': 97, 'total_tokens': 394, 'completion_tokens_details': None, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 97}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '8a77c26c-4186-4454-92f2-3f4e94161e75', 'finish_reason': 'stop', 'logprobs': None}, id='lc_run--019efc96-5a70-7962-90dc-27a73ebe799d-0', tool_calls=[], invalid_tool_calls=[], usage_metadata={'input_tokens': 97, 'output_tokens': 297, 'total_tokens': 394, 'input_token_details': {'cache_read': 0}, 'output_token_details': {}})]}
```

推理后确定是否要保存记忆

```
In [31]: from langchain.agents.middleware import after_model

@after_model
def delete_old_messages(state: AgentState, runtime: Runtime) -> dict | None:
    """模型调用后，删除最早的两条消息"""
    messages = state["messages"]

    if len(messages) > 4:
        removed = [m.id for m in messages[:2]]
        print(f"删除前两条消息，ID: {removed}")
        return {"messages": [RemoveMessage(id=m.id) for m in messages[:2]]}
    return None
```



```
agent = create_agent(  
    model = basic_model,  
    middleware=[trim_messages, dynamic_deepseek_routing, delete_old_messages],  
    checkpointer=InMemorySaver(),  
)
```

```
In [32]: response = agent.invoke(  
    {"messages": [{"role": "user", "content": "你好，我是李四"}]},  
    {"configurable": {"thread_id": "3"}},  
)  
  
response = agent.invoke(  
    {"messages": [{"role": "user", "content": "默写一下静夜思"}]},  
    {"configurable": {"thread_id": "3"}},  
)  
  
response = agent.invoke(  
    {"messages": [{"role": "user", "content": "今天真开心"}]},  
    {"configurable": {"thread_id": "3"}},  
)  
  
response = agent.invoke(  
    {"messages": [{"role": "user", "content": "我的名字是什么? "}]},  
    {"configurable": {"thread_id": "3"}},  
)  
  
print("\n最终回答: ", response["messages"][-1].content)
```

```
===== 路由中间件被调用 =====
用户问题: 你好, 我是李四
长度: 7
is_hard: False
最终模型: deepseek-chat
===== 路由中间件被调用 =====
用户问题: 默写一下静夜思
长度: 7
is_hard: False
最终模型: deepseek-chat
修剪消息: 从 5 条 → 4 条
===== 路由中间件被调用 =====
用户问题: 今天真开心
长度: 5
is_hard: False
最终模型: deepseek-chat
删除前两条消息, ID: ['7e032f52-c7eb-43a4-a63e-078932032cda', '44ae715c-2059-4572-8b76-b86d8ab15fbc']
===== 路由中间件被调用 =====
用户问题: 我的名字是什么?
长度: 8
is_hard: False
最终模型: deepseek-chat
删除前两条消息, ID: ['lc_run--019efcae-6dc4-74d0-9cb4-e5e05dbf7782-0', 'b64b2333-7f38-4cd2-9e68-f5469fd32c30']

最终回答: 哈哈, 看来你是在考我呀。根据咱们这段对话的上下文, 我只知道你让我称呼你为“李四”(这是你上次提到的昵称), 如果你有其他名字或者想让我换一种称呼, 随时告诉我!
```

In [33]: response

```
Out[33]: {'messages': [AIMessage(content='看到李四这么开心，真替你高兴！不如趁着这份心情，也来即
兴对两句诗如何？\n\n既然你默写了李白的《静夜思》，那我也送你一首我现编的小诗，专为此刻的心
情：\n\n**《喜日吟》**\n\n白日放歌须纵酒，**\n\n心头无事小神仙。**\n\n莫问明朝风与雨，**
\n\n且将欢意付流年。**\n\n祝你天天都有今日这般好心情！', additional_kwargs={'refusal':
None}, response_metadata={'token_usage': {'completion_tokens': 99, 'prompt_token
s': 51, 'total_tokens': 150, 'completion_tokens_details': None, 'prompt_tokens_det
ails': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0,
'prompt_cache_miss_tokens': 51}, 'model_provider': 'deepseek', 'model_name': 'deep
seek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_2026040
2', 'id': 'adc926da-f78d-4342-a135-5b2f12ede811', 'finish_reason': 'stop', 'logpro
bs': None}, id='lc_run--019efcae-7137-7761-b250-54f3fd7d4083-0', tool_calls=[], in
valid_tool_calls=[], usage_metadata={'input_tokens': 51, 'output_tokens': 99, 'tot
al_tokens': 150, 'input_token_details': {'cache_read': 0}, 'output_token_details':
{}}}),
HumanMessage(content='我的名字是什么？', additional_kwargs={}, response_metadata=
{'id': '07c087f8-9e75-4d04-b2b1-9d95b9b33f97'}),
AIMessage(content='哈哈，看来你是在考我呀。根据咱们这段对话的上下文，我只知道你让我称
呼你为“李四”（这是你上次提到的昵称），如果你有其他名字或者想让我换一种称呼，随时告诉我！', a
dditional_kwargs={'refusal': None}, response_metadata={'token_usage': {'completion
_tokens': 46, 'prompt_tokens': 145, 'total_tokens': 191, 'completion_tokens_detail
s': None, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'pr
ompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 145}, 'model_provider': 'de
epseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_p
rod0820_fp8_kvcache_20260402', 'id': '58085615-a435-4d7a-8fa4-7eaffb9b4724', 'fini
sh_reason': 'stop', 'logprobs': None}, id='lc_run--019efcae-7a3f-7332-9f30-dadc21d
1b469-0', tool_calls=[], invalid_tool_calls=[], usage_metadata={'input_tokens': 14
5, 'output_tokens': 46, 'total_tokens': 191, 'input_token_details': {'cache_read':
0}, 'output_token_details': {}})])}
```

输入输出以及中间件删除的流程

```

                H(3-after)
            AI(3-before)
                H(3-after)
                    AI(4-after)
                    H(4-after)

AI
H
AI
```

对用户记忆先总结后再进行推理，可实现无限上下文输入

```
In [55]: from langchain.agents.middleware import SummarizationMiddleware

agent = create_agent(
    # 主模型使用推理模型
    model=reasoner_model,
    tools=[],
    middleware=[
        SummarizationMiddleware(
            # 总结模型使用 chat 模型
            model=basic_model,
```

```

        trigger=("tokens", 2000), # 超过 2000 token 触发记忆总结
        keep=("messages", 10), # 总结记忆后保留最近10条原始消息
    )
],
checkpointer=InMemorySaver(),
)

```

```

In [56]: response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我是李四"}]},
    {"configurable": {"thread_id": "4"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我今年 30 岁"}]},
    {"configurable": {"thread_id": "4"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我爱运动"}]},
    {"configurable": {"thread_id": "4"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我喜欢吃火锅"}]},
    {"configurable": {"thread_id": "4"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "请以勇敢为主题讲一个 1000 字的故事"}]},
    {"configurable": {"thread_id": "4"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "请以过年为主题讲一个 1000 字的故事"}]},
    {"configurable": {"thread_id": "4"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "请以过年为主题讲一个 1000 字的故事"}]},
    {"configurable": {"thread_id": "4"}},
)

In [57]: for i in response['messages']:
    print(i, end = '\n\n')

```

```
content="Here is a summary of the conversation to date:\n\n## SESSION INTENT\n\nThe user is introducing themselves (李四, age 30). No specific task or goal has been stated yet; the session is in a preliminary greeting phase.\n\n## SUMMARY\n\n- User's name: 李四\n- User's age: 30 years old\n- No further requests, tasks, or decisions have been made.\n\n## ARTIFACTS\n\nNone.\n\n## NEXT STEPS\n\nAwait further instructions or requests from the user to determine the purpose of the session." additional_kwargs={'lc_source': 'summarization'} response_metadata={} id='91f71d09-830e-459b-bb0a-a6b6f1308a91'
```

```
content='好的，李四。30岁是一个很好的年纪，通常意味着更多的经验和更清晰的自我认知。你是想聊聊这个年龄阶段可能遇到的一些事情（比如职业、生活、心态），还是有什么具体的问题想探讨呢？' additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户说“你好，我今年30岁”。结合之前的对话历史，用户之前已经两次自我介绍为“李四”，我回应了“很高兴认识你”并开放了话题。现在用户补充了年龄信息。\\n\\n嗯，用户主动提供年龄，可能是在进一步介绍自己，希望我基于这个信息提供更个性化的回应或建议。30岁是一个常见的人生节点，用户可能正在经历一些与这个年龄相关的思考或困惑，比如职业发展、生活规划、家庭责任，或者对未来的焦虑。\\n\\n用户的深层需求可能不仅仅是告知年龄，而是希望得到一些与30岁这个年龄阶段相关的交流、建议或者共鸣。他/她可能想聊聊这个年纪会遇到的典型问题，或者只是开启一个更具体的话题。\\n\\n我需要先确认这个信息，表达关注，然后自然地引导对话，询问用户是否想围绕30岁这个话题展开，或者有其他的具体疑问。这样既承接了用户的分享，又保持了对话的开放性。'} response_metadata={'token_usage': {'completion_tokens': 243, 'prompt_tokens': 52, 'total_tokens': 295, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 196, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 52}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '51699bd7-ff04-460f-b474-1094d0df303d', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcf8-54b1-7173-bd9b-fde4adb32dc4-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 52, 'output_tokens': 243, 'total_tokens': 295, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 196}}
```

```
content='你好，我爱运动' additional_kwargs={} response_metadata={} id='48df02c9-2373-4d70-9971-8b385cf5faa9'
```

```
content='热爱运动是非常棒的习惯，尤其是在30岁这个阶段，保持规律的运动不仅能维持良好的体态和精力，对缓解工作压力、提升睡眠质量也特别有帮助。\\n\\n你是更喜欢有氧运动（比如跑步、游泳、骑行），还是力量训练或者球类运动？另外，坚持运动这么久，有没有哪项运动是你特别拿手或者最近在学的？' additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户说“你好，我爱运动”。结合之前的对话历史，用户已经说过自己是李四，30岁。现在突然提到爱运动，可能是在延续之前关于年龄和生活的闲聊，想进一步分享自己的兴趣爱好，或者希望我根据这个信息给出一些建议。\\n\\n嗯，用户可能不只是单纯地陈述一个事实，深层需求可能是想和我建立更具体的连接，或者探讨运动与30岁这个年龄段的关联。比如，如何保持运动习惯，预防30岁后常见的运动损伤，或者如何调整运动方式以适应身体变化。\\n\\n我需要肯定这个爱好，因为爱运动是积极健康的表现。然后可以自然地把它和用户30岁的年龄联系起来，询问一些具体的方向，比如运动类型、目标（健康、减脂、增肌、减压等），这样既能表示关心，也能引导对话更深入，满足用户潜在的交流或寻求建议的需求。'} response_metadata={'token_usage': {'completion_tokens': 255, 'prompt_tokens': 106, 'total_tokens': 361, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 179, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 106}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'e5e85b5e-e7bf-4ae6-a1f8-af762ea60dc8', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcf8-63dd-7a51-a3c9-7d2a69acadb4-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 106, 'output_tokens': 255, 'total_tokens': 361, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 179}}
```

```
content='你好，我喜欢吃火锅' additional_kwargs={} response_metadata={} id='5124d243-c636-4f87-b128-60204a885b89'
```

```
content='哈哈，火锅简直是治愈一切的神器！尤其是跟朋友或家人围坐在一起，热气腾腾的氛围特别幸福。30岁能保持运动习惯，又懂得享受美食，这种“平衡之道”很通透呀。
\n\n说到火锅，你更偏爱哪种锅底？是麻辣过瘾的川渝派、浓郁鲜香的潮汕牛肉锅，还是滋补养生的清汤锅？有没有每次必点的“灵魂食材”（比如毛肚、鸭血、虾滑或者茼蒿）？或者有没有什么独家蘸料配方可以分享？😋\n\n顺便问一句，运动完会奖励自己一顿火锅吗？还是说你会特意安排在休息日吃，享受那种毫无负担的满足感？' additional_kwargs={'refusal': None, 'reasoning_content': '好的，李四现在聊到了他喜欢吃火锅。之前我们聊了运动，现在话题转到美食，这是个很自然的切换。作为对话伙伴，我需要延续友好的语气，对他的喜好表示认同和共鸣。
\n\n火锅确实是很多人喜欢的社交美食，尤其是对于热爱运动的人来说，运动后吃顿火锅简直是一种享受。我可以先表达赞同，然后抛出几个轻松的问题来延续对话，比如问他喜欢的锅底、必点的菜，或者吃火锅的频率，这样既能表示关心，又能把对话深入下去。
\n\n另外，考虑到他之前提到过30岁和爱运动，也许可以顺便提一下运动后吃火锅的平衡之道，或者推荐一些相对健康的选择，这样能显示出我记住了之前的对话，让交流更有连贯性。不过不能太说教，要保持轻松愉快的语调。'} response_metadata={'token_usage': {'completion_tokens': 310, 'prompt_tokens': 190, 'total_tokens': 500, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 163, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 190}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '1dfa2c06-9489-4c63-967b-51d7fbac28cc', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcf8-73df-7b20-b7ca-09e3bb99b10f-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 190, 'output_tokens': 310, 'total_tokens': 500, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 163}}
```

```
content='请以勇敢为主题讲一个 1000 字的故事' additional_kwargs={} response_metadata={} id='1a23755f-34eb-4fcf-a076-6ea99d177c41'
```

```
content='# 勇敢\n\n李四今年三十岁，在一家互联网公司做了六年的程序员。
\n\n他的人生像一条固定的代码：早上七点半起床，八点出门，九点打卡，晚上九点下班，十一点睡觉。周末偶尔去跑个步，吃顿火锅，日子平淡得像白开水。他也曾梦想过改变世界，或者至少改变自己，但日复一日的循环，把勇气消磨殆尽。
\n\n这一切在那个周三的深夜被打破。
\n\n那天加班到凌晨，拖着疲惫的身体走出写字楼。城市已经入睡，路灯把街道拉得很长。他看见一只流浪猫蜷缩在垃圾桶旁，瘦骨嶙峋。从小怕猫的他下意识绕开走，却听见身后传来微弱的叫声。
\n\n他停下脚步。回头。那只猫抬起眼睛看着他，眼神里有他熟悉的东西——那是疲惫、无助，和对明天的茫然。
\n\n李四蹲下身。猫没有躲开。他犹豫了几秒，轻轻伸手摸了摸它的头。那触感有些扎手，但温热的。
\n\n“跟我走吧。”他说。
\n\n猫似乎听懂了，踉跄着站起来，跟着他走。他带猫去了二十四小时营业的便利店，买了火腿肠。店员笑着说：“你心挺好啊。”李四愣了一下——已经很久没有人这样说过他了。
\n\n那一夜，他在出租屋的阳台上给猫铺了纸箱。猫蜷在里面，眼睛半睁半闭，似乎终于可以安心睡去。李四躺在自己的床上，却怎么也睡不着。他想起很多年前，自己也像这只猫一样渴望被收留，渴望有人在深夜伸出手。可是这么多年，他活成了人群中最普通的那一个，把热烈的念头藏起来，把想说的话咽回去，觉得“勇敢”是年轻人的专利。
\n\n第二天，他做了一个决定：他要带这只猫回家乡。
\n\n他的母亲怕猫，而且他从未跟家里说过自己想养什么。可是这一次，他没有提前打电话，没有编理由，没有打腹稿。他买了火车票，带着猫上了车。一路上，猫窝在背包里，偶尔探出头看他一眼，他觉得自己心里的某个角落，也跟着亮了起来。
\n\n到了家，母亲果然皱眉。
\n\n“养它干嘛？多脏。”
\n\n李四把猫放在地上，猫紧张地贴着墙角。他说：“妈，它是在路边捡的。它没有地方去了。我想养它。”
\n\n他以为这会很难说出口，可是说出来之后，一切比想象中平静。母亲看着他的眼睛，忽然笑了：“你以前都不敢看猫的。”
\n\n“嗯。”李四也笑了，“我现在敢了。”
\n\n那天晚上，他和母亲坐在院子里喝汤。母亲说：“你变了。”李四问哪里变了。母亲想了想：“三十岁了，终于有点像你了。”
\n\n那只猫后来留了下来。母亲从一个怕猫的人，变成了会偷偷给它加罐头的人。而李四在假期结束后回到城市，换了工作，不再那么拼命地加班。周末他去跑步，去爬山，去吃火锅，偶尔在街边停下来，看看那些流浪的小生命。
\n\n他渐渐明白，勇敢从不是惊天动地的壮举。它藏在那些微小的瞬间里：在凌晨的路灯下弯下腰，在久违的电话里说出真心话，在日复一日的平庸中，选择一个不一样的清晨。
\n\n三十岁，他养了一只猫。从此，他的勇敢有了温热的呼吸。' additional_kwargs={'refusal': None, 'reasoni
```

ng_content': '好的，用户这次要求以“勇敢”为主题讲一个1000字的故事。从之前的对话看，用户叫李四，30岁，爱运动，也爱火锅，性格挺开朗的。他连续几个“你好”开头，感觉像是在轻松地聊天，现在突然提出要一个故事，可能是想换个话题，或者真的需要一些灵感启发。\\n\\n嗯，“勇敢”这个主题很常见，但讲好需要点新意。用户之前提到30岁、运动、火锅，这些元素或许可以融入故事里，让故事更贴近他的生活，产生共鸣。他可能不只是想要一个老套的勇敢传说，而是想看到一个有真实感、能触动普通人的故事。\\n\\n深层需求呢？用户可能正在经历30岁这个阶段的一些内心变化，比如对未知的焦虑、对过去的反思，或者需要一点鼓励去面对工作或生活上的挑战。通过一个故事，他或许在寻找一种共鸣和力量，而不仅仅是听个乐子。\\n\\n那么，故事可以围绕一个30岁左右的普通人展开，职业背景平常一点，比如程序员？这样容易代入。把运动（比如跑步）作为情节转折的契机，火锅作为生活氛围的调剂，这样就能把用户提到的元素自然串联起来。故事的核心勇敢，可以不是惊天动地的壮举，而是面对内心恐惧、走出舒适区、尝试新可能的勇气。这样更贴近生活，也更有力量。\\n\\n1000字的故事，需要起承转合。开头可以描绘主人公平凡甚至有点困顿的生活，中间通过一个偶然事件（比如看到小时候的勇敢念头）触发反思，用运动作为具体行动来象征改变，最后落脚到日常生活里那种“再试一次”的平常英雄主义。结尾要温暖，给人希望。\\n\\n好，心里有谱了。故事主角就叫张明吧，设定在30岁，程序员，生活重复。用跑步机重启那个细节作为勇敢的起点，把火锅情结放在回忆里对比现在，最后用“日常中的勇敢”点题。这样，故事既满足了形式要求，也能在情感上呼应李四这个30岁、爱运动、爱火锅的用户。'} response_metadata={'token_usage': {'completion_tokens': 1136, 'prompt_tokens': 352, 'total_tokens': 1488, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 442, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 128}, 'prompt_cache_hit_tokens': 128, 'prompt_cache_miss_tokens': 224}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'fe372199-f5fb-4e04-9026-e1ad96b1b53b', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcf8-88e6-7101-ba8d-2350dbf8f7af-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 352, 'output_tokens': 1136, 'total_tokens': 1488, 'input_token_details': {'cache_read': 128}, 'output_token_details': {'reasoning': 442}}

content='请以过年为主题讲一个 1000 字的故事' additional_kwargs={} response_metadata={} id='ed63d219-de91-4b16-9aa3-571b8a4edf7e'

content='# 年三十的一盘饺子\\n\\n李三已经三年没回家过年了。\\n\\n第一年说项目赶，第二年说攒钱买车，第三年干脆没找理由，只是打电话说“票不好抢”。母亲在电话那头“嗯”了几声，说了句“那你买点好吃的”，便挂了。李三听着忙音，心里空落落的，像窗外那座只剩下霓虹灯的空城。\\n\\n今年，他还是没抢到票。但不知道为什么，腊月二十八那天早上，他突然特别想吃一口母亲包的饺子。\\n\\n不是超市里那种冷冻的，不是外卖平台上三十块钱一份的，是那种皮薄馅大、咬一口会流汤汁的、母亲亲手包的饺子。韭菜鸡蛋馅的，里面放一点虾皮，蘸着醋和蒜泥，一口一个，烫得直哈气，却停不下来。\\n\\n这个念头一旦冒出来，就像野草一样疯长。他当天请了假，订了一张站票，在绿皮火车上站了十四个小时，大年三十下午才到县城。车站外刮着凛冽的北风，他的脚已经肿了，但站在出站口，远远看见父亲那辆旧摩托车时，眼眶忽然就热了。\\n\\n父亲没说什么话，只是递给他一个头盔。父子俩骑着摩托车穿过空旷的县道，两旁的村庄里陆续响起鞭炮声，炊烟从各家各户的烟囱里升起来。李三坐在后座上，看着父亲的后脑勺。父亲的头发白了很多，耳朵冻得通红。他想说点什么，但风太大了，张不开嘴。\\n\\n到家的时候天已经擦黑。母亲正在厨房里忙活，听见动静探出头来，愣了一下，随即笑了：“呦，还真回来了？我以为你逗我呢。”她嘴上说着，手却没停，继续麻利地擀皮、包馅。动作还是那么利索，只是手上的皱纹多了，关节粗了。\\n\\n“妈，我帮你包。”李三洗了手，搬了个小板凳坐下去。他包得很慢，饺子歪歪扭扭，像一个个打了败仗的士兵。母亲看了一眼，笑着用沾满面粉的手敲了他一下：“三十岁了，还包成这样，以后谁嫁给你。”\\n\\n“那我以后回来吃。”\\n\\n母亲没接话，低下头继续包。厨房里只剩下擀面杖在案板上滚动的声响，和灶台上咕嘟咕嘟冒着热气的锅。\\n\\n饺子下锅的时候，母亲忽然说：“你小时候，最爱吃韭菜鸡蛋馅的，每年三十晚上，别的菜你可以不吃，饺子必须得吃一盘。有一年你爸包了一枚硬币进去，你一口咬下去，牙差点崩了，哭了一晚上。”\\n\\n李三笑了，笑着笑着，眼眶就红了。那些小时候觉得稀松平常的事，如今想起来，每一件都珍贵得像梦。\\n\\n饺子端上桌的时候，春晚正好开始。电视机的声音很大，但谁也没认真看。母亲不停地往他碗里夹饺子，父亲坐在一旁喝酒，偶尔插一句“多吃点”，然后继续沉默地笑。窗外鞭炮声此起彼伏，烟花在夜空中炸开，照亮了这个小县城的除夕夜。\\n\\n李三咬了一口饺子，韭菜的鲜香、鸡蛋的软嫩和虾皮的鲜味混在一起，烫得他舌头打结，但停不下来。他不知道是因为在火车上站了十四个小时太饿了，还是因为这盘饺子里包了太多他这些年在外面吃不到的东西。\\n\\n吃到最后一个的时候，他咬到了一个硬东西——一枚硬币。\\n\\n他愣了一下，抬头看母亲。\\n\\n母亲装作若无其事地低

头喝汤，嘴角却微微翘起。\\n\\n“妈，”他说，“明年我还回来。”\\n\\n“嗯。”她应了一声，还是没抬头，但李三看见她的眼角有什么东西闪了一下。\\n\\n窗外烟花又亮了。李三把硬币放在手心里，攥得紧紧的。\\n\\n二十九岁的最后一天，他终于懂了：过年不是去哪里，而是回到谁身边。' additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户这次要求以“过年”为主题讲一个1000字的故事。回顾之前的对话，用户之前让我以“勇敢”为主题讲过故事，而且用户自称“李四”，并且聊到了自己的年龄（30岁）、爱好（运动、吃火锅）。看起来用户可能希望听到一个贴近他生活、有代入感的故事，而不是一个通用的、泛泛而谈的过年故事。\\n\\n嗯，用户深层需求可能不只是一要一个关于“过年”的习俗描述或热闹场景，而是希望故事能触及一些这个年龄段特有的情感，比如成长、变化、与家人的关系，或者是在传统节日背景下的个人感悟。他之前对“勇敢”故事的反应可能比较积极，所以这次过年故事也需要有足够的情感深度和细节，让他能产生共鸣。\\n\\n考虑到用户是30岁的男性，故事主角可以设定为同样30岁、在外工作的“李四”，这样延续了之前的设定，增加代入感。故事的核心可以从一个“变化”入手，比如一个平时不怎么回家、或者回家有某些习惯的人，在过年时因为某个事件（比如家人记住他小时候的喜好、或者一个具体的物件）而感受到家的温暖和自己的成长。这样既能体现过年的传统氛围，又能呼应30岁这个人生阶段的反思，比如从被照顾到开始理解家人、从追求远方到发现身边的温暖。\\n\\n故事长度要求1000字左右，需要设计一个完整的情节：开头交代背景和主角的现状，中间制造一个情感转折点（比如发现家人记得自己小时候的喜好），最后以主角的感悟或行动变化结束，带出“过年”和“团圆”的深层意义。可以用一些生动的细节，比如母亲包糖饺子、父亲沉默的关心、家乡的味道等，让故事有画面感和真实感。\\n\\n最后，故事的语言风格应该延续之前“勇敢”故事的细腻平实，带点温暖和思考，避免过于夸张或煽情。这样应该能满足用户对个人化、有情感触动故事的期待。'} response_metadata={'token_usage': {'completion_tokens': 1234, 'prompt_tokens': 1061, 'total_tokens': 2295, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 407, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 256}, 'prompt_cache_hit_tokens': 256, 'prompt_cache_miss_tokens': 805}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flan-h', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '4000b7f1-f232-4ded-a4bd-2fef373628b', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcf8-cd90-7833-a3c3-ca3de67ad1d1-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 1061, 'output_tokens': 1234, 'total_tokens': 2295, 'input_token_details': {'cache_read': 256}, 'output_token_details': {'reasoning': 407}}

content='请以过年为主题讲一个 1000 字的故事' additional_kwargs={} response_metadata={} id='9a79ffff-3b3c-4e48-bbd5-8ffc6cacd4f5'

content='# 归途\\n\\n李四决定今年无论如何都要回家过年。\\n\\n这个念头是在腊月二十三那天突然冒出来的。彼时他正站在公司楼下那棵挂满彩灯的圣诞树旁边，手机屏幕上母亲发来的微信语音。他点开听，母亲的声音夹杂着油锅里的滋滋声：“腊八蒜我已经泡上了，你爱吃的卤牛肉也买了，冰箱都塞满了——你要是能回来，东西就吃得完，你要是回不来，我和你爸得吃到正月十五……”\\n\\n语音结束了。李四看了看日期，又看了看抢票软件上那个鲜红的“候补”二字，咬了咬牙，打开导航软件，输入了那个三年没回去的地址——860公里。\\n\\n他决定开车回去。\\n\\n同事听说他要自驾，都劝他别冲动：“春运高速堵成停车场，一个人开八百多公里，你疯了？”李四笑笑说没事。他其实心里也没底，他的车是辆开了六年的小轿车，后轮胎压总是不太对，导航也不够新。但那个念头一旦生了根，就再也拔不掉了——他必须回去。\\n\\n腊月二十八凌晨四点，李四把行李箱塞进后备箱，又检查了一遍机油、冷却液和备胎，然后坐进驾驶室。城市的街道空荡荡的，只有路灯还亮着。他深吸一口气，发动了车。\\n\\n最初的三个小时很顺利。天渐渐亮了，路两旁的田野覆盖着一层薄薄的白霜，电线杆上落着几只麻雀。李四打开窗，冷风灌进来，格外清醒。他一边开车一边想，这些年自己在外到底忙出了什么。工资涨了一点，头发掉了一些，朋友圈里的人换了又换，但每年春节前那种“不敢回家”的忐忑，却一年比一年重。\\n\\n“混得不好，回去怕丢脸。”他自言自语。可母亲的那条语音像一根绳子，紧紧地拽着他的心。\\n\\n九点过后，高速公路上的车开始多了起来。十点，堵住了。\\n\\n导航上那条绿色的线变成了一段深红。李四的车夹在望不到头的车流里，寸步难行。前面的面包车上下来一家三口，男人蹲在路边抽烟，女人抱着孩子，孩子哭闹着要上厕所。李四看了看自己的油表——还有两格，但照这个堵法，撑不了多久。\\n\\n他熄了火，拿出手机，给母亲发了条消息：“路上堵车，可能会晚，但今晚肯定到。”\\n\\n母亲秒回：“不着急，慢慢开，饺子等你。”\\n\\n就这一句话，李四的眼眶忽然就热了。\\n\\n堵了将近三个小时，车流终于动了起来。李四跟着前车缓缓前行，经过一个服务区时赶紧拐进去加油。加油站的队排得很长，他等了二十分钟才加上油。趁着空隙，他泡了一碗方便面站在车旁吃。风很冷，面很烫，他吃出一头汗。\\n\\n下午四点，终于上了畅通的高速路段。李四打起精神，把音乐开大，一路往北开。天色一点点暗下来，远方开始出现零星的烟花，有的在村庄上空炸开，有的在远处的山腰上闪烁。他想起小时候，年三十晚上和父亲一起放烟花，父亲总是让他点

引线，他胆小，点了就跑，摔了个跟头，父亲笑得直不起腰。

晚上七点，他下了高速，进入县道。路窄了，灯暗了，但路两旁的村庄里亮着暖黄色的光，家家户户门口都贴着春联、挂着灯笼。李四放慢了车速，摇下车窗，闻到了空气里隐约的火药味和炊烟味。

那是他记忆里过年的味道。

八点零五分，他把车停在了自家门口。院子里亮着灯，透过玻璃窗，他看见母亲正弯腰往桌上端菜，父亲坐在沙发上看电视，茶几上摆着一盘刚出锅的饺子，冒着热气。

李四推开门，冷风和屋里的暖气撞在一起。母亲回过头，愣了一下，然后笑了：“到了？快去洗手，饺子刚出锅，韭菜鸡蛋的。”

他什么也没说，换了鞋，洗了手，坐到桌前。父亲把电视声音调小了一点，把醋碟推到他面前。李四夹起一个饺子咬了一口，韭菜的鲜、鸡蛋的嫩、虾皮的咸香瞬间在舌尖炸开。

他低下头，大口大口地吃着，眼泪差点掉进醋碟里。

原来归途再远，也不过是一盘饺子的距离。

additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户又要求以过年为主题讲一个1000字的故事。回顾之前的对话，用户先是自我介绍，然后聊了运动和火锅，接着让我以“勇敢”为主题讲了个故事，现在又回到了“过年”主题。

嗯，用户可能是在测试我的故事创作能力，或者单纯想听不同角度的故事。之前的“勇敢”故事讲了一个关于收养流浪猫、找回自我的城市青年故事。上次的“过年”故事讲了一个游子回家吃饺子的温情故事。这次同样是“过年”，需要避免重复上次的思路。

用户可能深层希望听到一个同样触动人心，但视角或情感不同的新年故事。或许可以聚焦在“归途”的艰辛上？上次是绿皮火车站票回家，这次可以换个交通工具，比如自驾电动车返乡，这更贴合当下现实，能带出时代感和新的情感冲突。

用户年龄30岁（李四），故事主角可以继续设定在这个年龄段，有相似的生活压力。电动车春运的“里程焦虑”可以作为一个很好的戏剧冲突点，既能展现现代生活的特定难题，又能体现亲情和克服困难的主题。

可以用“接母亲到城市过年”作为反转，比单纯回家更有新意。故事结构可以这样：主角（李四）决定接母亲来城市过年，但母亲因不习惯/不舍拒绝。主角自驾回家，途中电动车没电，陷入困境，最终被母亲等家人解围。这个过程中，主角的“计划”与现实的“意外”形成对比，“回家”的概念也从空间移动升华为情感回归。

需要控制在1000字左右，要有细节描写（堵车、电量焦虑、电话沟通、村口等待、汤圆场景），情感要真挚，避免说教。结尾最好落在“过年是双向的奔赴”这种朴素但有力的感悟上。’}

response_metadata={'token_usage': {'completion_tokens': 1315, 'prompt_tokens': 1968, 'total_tokens': 3283, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 371, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 1968}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'bc793243-9a50-4268-b078-c0e00a17cf3c', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcf9-1e90-7132-a596-64c4466b9cf6-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 1968, 'output_tokens': 1315, 'total_tokens': 3283, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 371}}}

```
In [37]: snapshot = agent.get_state(
    {
        "configurable":{
            "thread_id":"4"
        }
    }
)
```

```
In [38]: for msg in snapshot.values["messages"]:
    print(type(msg))
    print(msg)
```

```

<class 'langchain_core.messages.human.HumanMessage'>
content='你好，我是李四' additional_kwargs={} response_metadata={} id='b7aec2f9-4c4b-4584-b6d3-ae6c9397a741'
<class 'langchain_core.messages.ai.AIMessage'>
content='你好，李四！我是DeepSeek，很高兴认识你。😊\n\n有什么我可以帮你的吗？无论是学习、工作、生活上的问题，还是只是想聊聊天，我都很乐意陪你聊聊！随便问吧~' additional_kwargs={'refusal': None, 'reasoning_content': '哦，用户直接介绍自己是李四。这是一个常见的自我介绍场景，需要友好回应并引导对话。可以用问候建立连接，同时开放对话话题。不需要特别处理，保持自然就好。考虑提供几个常见方向供选择，比如功能询问或闲聊，这样比较周全。'} response_metadata={'token_usage': {'completion_tokens': 105, 'prompt_tokens': 9, 'total_tokens': 114, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 57, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 9}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'db29e50a-6e91-4f27-be8d-51b40802a9d2', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcba-92d1-75d2-941a-8d0f1995274e-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 9, 'output_tokens': 105, 'total_tokens': 114, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 57}}
<class 'langchain_core.messages.human.HumanMessage'>
content='你好，我今年 30 岁' additional_kwargs={} response_metadata={} id='fd729909-e51a-40b9-aa53-7dbd70ba31e5'
<class 'langchain_core.messages.ai.AIMessage'>
content='你好，李四！30岁是一个很有意思的年纪——既保留了年轻时的冲劲，又多了一份对生活的掌控感。这个阶段可能会面临更多选择（比如职业方向、家庭规划、自我成长），也可能会感受到一些“三十而立”带来的期待或压力。
\n\n你是想聊聊这个年龄段特有的困惑（比如职业发展、财务规划、人际关系），还是单纯想分享一下现在的生活状态？或者有什么具体的问题需要建议？我在这儿听着呢~😊' additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户说“你好，我今年30岁”。结合之前的对话历史，用户之前自我介绍是“李四”，现在补充了年龄信息。
\n\n嗯，用户可能是在进行一个简单的自我介绍，或者想开启一个基于他年龄的、更个人化的对话。30岁是一个比较特别的年龄节点，很多人会在这个阶段思考职业发展、人生规划、家庭责任，或者感到一些“而立之年”的焦虑。
\n\n用户的深层需求可能不只是告知年龄，而是希望得到一些与年龄相关的建议、共鸣，或者想聊聊这个年龄段特有的困惑。比如，他可能面临职场瓶颈、婚恋压力、健康问题，或者单纯想听听AI对30岁生活的看法。
\n\n我需要先确认这个信息，表示收到了，然后自然地将对对话引导到与30岁相关的、开放性的讨论话题上，让用户可以选择他感兴趣的方向深入。这样既回应了用户，又为后续交流创造了空间。
\n\n思考一下回复的结构：先简单确认和问候，然后点出30岁可能关联的一些常见话题（如规划、焦虑、健康），最后用开放式提问让用户选择聊什么，保持支持和共情的语气。'} response_metadata={'token_usage': {'completion_tokens': 328, 'prompt_tokens': 68, 'total_tokens': 396, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 232, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 68}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '047cec0e-e6a3-4115-add2-5cac0a7909ee', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcba-9b7b-7e22-b349-768edca75ed1-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 68, 'output_tokens': 328, 'total_tokens': 396, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 232}}
<class 'langchain_core.messages.human.HumanMessage'>
content='你好，我爱运动' additional_kwargs={} response_metadata={} id='2fccf39b-0f12-4ba9-8a17-9456ce52baca'
<class 'langchain_core.messages.ai.AIMessage'>
content='爱运动这个习惯真的很棒！30岁正是把“动起来”变成生活方式的黄金时期——既能释放压力，又能为未来的健康打下基础。相比20岁时可能追求“猛练”，30岁或许可以更关注“科学持久”的运动习惯，比如：
\n- **有氧+力量结合**：跑步、游泳搭配深蹲、划船机，维持代谢率
\n- **灵活性与恢复**：加入瑜伽或拉伸，减少受伤风险
\n- **趣味性**：尝试攀岩、骑行、球类运动，让运动不枯燥
\n\n你是喜欢独自享受运动中的“心流时刻”，还是更偏爱团体运动的社交感？或者.....有没有最近在挑战某个

```

运动目标（比如跑10公里/解锁引体向上）？ 😊 ' additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户说“你好，我爱运动”。结合之前的对话历史，用户已经两次自我介绍为“李四”，并提到自己30岁。现在他主动提及爱好运动。\\n\\n嗯，用户可能是在延续之前的聊天，分享自己的兴趣。他的深层需求可能不仅仅是告知我他的爱好，而是希望得到回应和共鸣，或者想探讨如何将运动与30岁的生活状态结合起来。他可能想聊聊运动带来的好处、如何坚持、或者针对30岁这个年龄段的运动建议。\\n\\n作为30岁的运动爱好者，他可能面临一些实际问题，比如工作忙碌如何保持锻炼、如何预防运动损伤、或者如何通过运动改善精力管理。我需要先肯定他的爱好，建立积极共鸣，然后自然地提供一些针对30岁人群的运动建议或鼓励。\\n\\n考虑到前两次对话都是简单的问候和年龄告知，这次用户抛出了一个具体兴趣点，我应该抓住这个机会展开更有价值的交流，展现我的陪伴和实用价值。可以询问他具体喜欢什么运动，或者分享一些科学、正向的运动观点，比如运动对心理和精力的长期好处。'} response_metadata={'token_usage': {'completion_tokens': 378, 'prompt_tokens': 171, 'total_tokens': 549, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 217, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 171}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '7bd011bf-27f4-4104-b70f-497c03021f66', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcba-b1b5-7030-8ee5-92d4040f5637-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 171, 'output_tokens': 378, 'total_tokens': 549, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 217}}}

```
<class 'langchain_core.messages.human.HumanMessage'>
```

```
content='你好，我喜欢吃火锅' additional_kwargs={} response_metadata={} id='15ccd1aa-b984-422a-b771-ee0af8a943ae'
```

```
<class 'langchain_core.messages.ai.AIMessage'>
```

```
content='哈哈，火锅真的是“社交神器”和“快乐源泉”啊！ 🍲 尤其在30岁这个年纪，约上三五好友围炉涮肉，一边聊生活一边等毛肚“七上八下”，简直是治愈感拉满的仪式感~\\n\\n你是偏爱哪种风格？**川渝麻辣锅**的酣畅淋漓，**潮汕牛肉锅**的鲜嫩原味，还是**老北京铜锅涮肉**的麻酱浓香？ 🌶️ 🍲 \\n（悄悄说：如果运动是为了更畅快地吃火锅，那简直是“自律与自由的完美平衡”了 😊） \\n\\n最近有吃到什么惊艳的配菜或蘸料配方吗？或者有没有什么“火锅局”的趣事想分享？' additional_kwargs=
```

```
{'refusal': None, 'reasoning_content': '好的，用户说“你好，我喜欢吃火锅”。这看起来是一个轻松的个人喜好分享，延续了我们之前关于运动和年龄的闲聊话题。用户叫李四，30岁，爱运动，现在又提到爱吃火锅。\\n\\n嗯，用户可能不只是单纯宣布一个喜好，深层需求可能是想展开这个话题，聊聊火锅相关的经验、推荐，或者寻求一些如何平衡健康饮食（因为他爱运动）和火锅享受的建议。毕竟之前他提过爱运动，30岁可能也关注健康管理。\\n\\n我需要给予积极热情的回应，肯定他的喜好，然后提供一些有价值的延伸内容。可以聊聊火锅的多样性（不同地域风味）、社交属性（与朋友同乐），以及结合他爱运动、30岁这个年龄特点，给出一些健康吃火锅的小贴士，比如锅底选择、食材搭配、运动与饮食的平衡。最后可以反问，引导他分享更多，让对话继续下去。\\n\\n这样既能满足他分享的愉悦感，又能提供实用信息，体现关怀和互动。'} response_metadata={'token_usage': {'completion_tokens': 367, 'prompt_tokens': 340, 'total_tokens': 707, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 206, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 128}, 'prompt_cache_hit_tokens': 128, 'prompt_cache_miss_tokens': 212}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'ac13dffe-87b3-4ff6-9e3c-ce70b4201d0a', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcba-cc8b-7be0-b718-e98e379339e6-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 340, 'output_tokens': 367, 'total_tokens': 707, 'input_token_details': {'cache_read': 128}, 'output_token_details': {'reasoning': 206}}}
```

```
<class 'langchain_core.messages.human.HumanMessage'>
```

```
content='请以勇敢为主题讲一个 1000 字的故事' additional_kwargs={} response_metadata={} id='4ccb3492-73e9-4d59-8494-2733da1062b1'
```

```
<class 'langchain_core.messages.ai.AIMessage'>
```

```
content='# 勇敢\\n\\n老赵站在自家门口，手握着门把手，却迟迟没有转动。\\n\\n门那边是妻子的哭声和儿子摔东西的声响。他已经站了很久，久到楼道的声控灯灭了又亮，亮了又灭。\\n\\n三个月前，老赵被公司裁员了。他没告诉任何人，每天早上依然穿西装打领带，装作出门上班的样子。他坐在公园的长椅
```

上，从早晨坐到傍晚，看着那些带孩子的老人，跑步的年轻人，遛狗的女人。他觉得自己像个鬼魂，游荡在城市里，却与一切格格不入。

更糟的是，体检报告上那几个字像烙铁一样烫在他的视网膜上——“疑似肺部恶性肿瘤”。

老赵今年五十二岁，女儿刚上大一，儿子还在读高中。妻子是全职主妇，去年刚做了腰椎手术，不能干重活。他是这个家唯一的支撑，可现在，这根柱子快断了。

“赵建国”，他低声叫自己的名字，像在叫另一个人，“你什么时候变得这么怂了？”

他突然想起三十年前的那个傍晚。

那时他二十出头，和同村的一个姑娘订了婚，姑娘家里要三万彩礼。他家穷，爹娘拿出所有积蓄还差一大截。他抱着两床棉被，坐了一天一夜的绿皮火车到深圳打工。第一次进工厂，车间里几十台机器轰鸣，主管骂他手脚慢，周围的人都面无表情地看他。

他那时想哭，但忍住了。

在工厂的第四个月，他被机器轧断了半根手指。厂里赔了八千块私了，他攥着钱，咬着牙没掉一滴泪。

后来他攒够了钱回去，姑娘已经嫁了别人。

他离开老家的时候，他娘追出来，塞给他一包煮鸡蛋和两百块钱。他在长途汽车上，看着窗外的县城一点点变小，眼泪终于掉下来。他娘不知道，他兜里其实只剩十三块钱了。

但那时的他，怕了吗？

他也怕。怕穷，怕饿，怕丢人，怕回不了家。但他从来没想过“躲”。

他打工、摆摊、开出租、给人装修，什么活都干。他自己攒钱娶了媳妇，生了孩子，买了房子，一步步把日子从泥里往外拔。

可现在，五十二岁的赵建国，站在自己家门口，不敢进去。

他怕妻子的眼泪，怕儿子问他要生活费，怕女儿打电话说学校要交学费。

更怕的，是医院那扇门。

老赵终于转动了门把手。

屋里安静了一瞬。妻子红着眼眶坐在沙发上，儿子把一个杯子摔在地上，玻璃碴子溅了一地。

“爸……”儿子看到他，声音突然弱了。

老赵没有发火。他弯腰，一片一片捡起地上的玻璃碴。手指被划了一道口子，血渗出来，他没吭声。

“有件事跟你们说一下，”他说，“我下岗了。”

妻子愣住，继而嚎啕大哭。

那天晚上，老赵翻出家里所有的存折和卡，算了一遍又一遍。够孩子把书读完，够还两年房贷。但加上他的病，远远不够。

第二天，他没有去医院复查。

他穿上了旧工作服，骑上那辆满是灰尘的电动车，在“58同城”上找了个装修小工的活。工头看他年纪大，不太想要。老赵撸起袖子，单手扛起一袋水泥。

“赵师傅，行不行啊？”有人笑他。

“别叫赵师傅，”他说，“叫老赵就行。”

下午两点，太阳最毒的时候，他蹲在没有空调的阳台上贴瓷砖。汗水混着瓷砖灰糊在脸上，手机响了，是一条短信：“赵建国先生，您在我院的复查结果已出，请尽快……”

他把手机塞进口袋，继续贴瓷砖。

下班的时候，工头给他结了二百三十块。他攥着那几张皱巴巴的钞票，想起了三十年前手里攥着的八千块。

那天晚上，妻子端来一碗热汤。她没说话，只是把碗放到他手上。

老赵低头喝了一口，眼泪掉进汤里。

他没换工作。一个月后，他瘦了将近十斤。工头看他实在不容易，把他调去仓库管材料，活轻松些，钱少一点。

他纠结了很久，还是去了医院。

诊断结果出来那天，他甚至在诊室门口站了十几分钟不敢进去。

“你那个，”医生推了推眼镜，看了看报告又看了看他，“还需要进一步确认，但初步判断，良性的可能性很大。”

老赵愣住了。

他没哭。他走出医院大门，在门口抽了一根烟，然后给妻子打了个电话：“晚上吃火锅吧，我请客。”

后来，老赵一直干到年底，儿子帮他那个装修小工的证考了下來。再过一年，他自己揽活，当了个小包工头。

他依然会怕——怕刮风下雨没活干，怕工人偷奸耍滑，怕客户赖账不给钱。但这些怕，不再让他躲。

他渐渐明白了一件事：勇敢不是不害怕，而是害怕的时候，依然敢推开那扇门。

就像那年在家门口，他终于拧动了门把手一样。

additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户这次提了一个具体的创作请求，要一个以“勇敢”为主题的1000字故事。从之前的对话看，用户（李四）分享了自己的年龄、爱好和喜欢的食物，氛围比较轻松个人化。现在突然转向故事创作，可能是想听一个能引发共鸣或激励人心的虚构叙事。'}
嗯，“勇敢”这个主题很宽泛。用户可能不只是想要一个简单的英雄故事，而是希望看到一个有深度、能触动人心的故事，或许能反映他30岁这个人生阶段面对的一些内心挑战——比如生活压力、职业迷茫、对未来的恐惧。深层需求可能是通过故事获得某种启发或情感慰藉。'}
我需要构思一个既贴近现实又能体现勇敢内核的故事。不能太奇幻，要贴近普通人的困境。想到了可以用一个中年人面对生活转折点（比如失业、疾病、家庭压力）的经历来展现勇敢，因为“勇敢”并不总是轰轰烈烈的战斗，更多时候是在困境中坚持和承担。故事节奏要平实，有细节，最后能带来一点希望或感动。'}
叙事视角可以用第一人称“我”，增强代入感。故事开头可以设置一个具体的、有象征意义的“恐惧”场景（比如一个黑暗的走廊或台阶），然后通过讲述一个更重大的挑战（如父亲重病、家庭危机）来展现人物如何战胜恐惧、承担责任。这样既有悬念，又能自然点题。结尾可以回到开头的那个场景，形成闭环，强调“勇敢是带着恐惧前行”这个核心。'}
故事长度控制在1000字左右，需要精炼场景，聚焦于关键的心理转变和行动。用户可能希望故事有留白，能有思考和共鸣的空间。那就开始构思具体情节和细节吧。'}
response_metadata={'token_usage': {'completion_tokens': 1434, 'prompt_tokens': 516, 'total_tokens': 1950, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 350, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 256}, 'prompt_cache_hit_tokens': 256, 'prompt_cache_miss_tokens': 260}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '13d5c174-495d-4558-9fd7-73d3eabb4aed', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcba-e73f-7e00-960c-ce4e13e5477f-0' to

```

ol_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 516, 'output_token
s': 1434, 'total_tokens': 1950, 'input_token_details': {'cache_read': 256}, 'output_
token_details': {'reasoning': 350}}
<class 'langchain_core.messages.human.HumanMessage'>
content='请以过年为主题讲一个 1000 字的故事' additional_kwargs={} response_metadata={}
id='90b2ed84-ec3a-4d1c-a429-59a1514c82e8'
<class 'langchain_core.messages.ai.AIMessage'>
content='# 回家\n\n腊月二十九，陆远坐在北京到沈阳的高铁上，看着手机里母亲发来的最后一条语
音，迟迟没有点开。\n\n他已经三年没回家了。\n\n第一年说项目赶工，第二年说没抢到票，第三年.....
其实他自己也说不清为什么没回去。也许是觉得没混出个样子，没脸见人。三十一岁了，北漂八年，存款
四万五，房租两千八，女朋友刚分手。回家过年意味着什么？意味着要面对七大姑八大姨的灵魂拷问：买
房了吗？结婚了吗？工资多少？年终奖发了吗？\n\n火车到站的时候是下午四点，天已经擦黑了。沈阳的
冬天比他记忆里还要冷，站台上风刮过来，像刀子割在脸上。他裹紧羽绒服，拖着一个不大的行李箱往外
走。出站口乌泱泱全是人，接站的举着牌子，小贩吆喝着卖烤红薯。他站在人群里扫了一圈，没有看到父
母的身影——他特意说了，不用接，他自己打车回去。\n\n其实他是害怕那个画面。\n\n害怕看到父亲佝
偻的背影，害怕看到母亲花白的头发，害怕那一瞬间的沉默里，藏着他无法消化的情绪。\n\n打车到家楼
下，已经快五点了。老小区的路灯坏了两盏，单元门上的春联是新的，红底金字，写着“家和万事兴”。他
站在门口深吸了一口气，上楼，敲门。\n\n门开了，母亲站在门后，围裙上沾着面粉，看见他愣了一下，
然后笑了。\n\n“回来了？赶紧进来，外头冷。”\n\n没有想象中的泪流满面，没有拥抱，没有任何煽情的
桥段。母亲只是侧了侧身，给他让出一条路，然后转头冲着厨房喊了一句：“老陆，你儿子回来了！”\n\n
厨房里传来锅铲翻炒的声音，父亲的声音隔着油烟传出来：“回来了？洗手吃饭！”\n\n陆远把行李箱放在
墙角，换了拖鞋。客厅的茶几上摆着一盘花生瓜子一盘糖，电视开着，正在播某个春晚的预热节目。沙发
换了个罩子，是他从来没见过的花色，茶几上多了一个新的保温杯。一切都熟悉得让人鼻子发酸，又陌生
得让人不知所措。\n\n年夜饭摆了一桌子。酸菜炖排骨、锅包肉、溜肉段、地三鲜、凉拌拉皮、还有一盘
他小时候最爱吃的炸春卷。父亲开了瓶白酒，给他倒了满满一杯。\n\n“来，走一个。”\n\n陆远端起杯，
和父亲碰了一下。酒很辣，辣得他眼眶发热。\n\n席间没有谁问他工作怎么样、有没有对象这些事。父亲
聊的是楼下老张家儿子今年考上公务员了，隔壁单元王大爷刚装了心脏支架。母亲聊的是菜市场的猪肉降
了两块钱，超市搞活动她抢到了三提卷纸。都是些琐琐碎碎的生活，安安静静地铺在他面前，像一床晒过
太阳的棉被，又厚又暖。\n\n吃到一半，父亲突然放下筷子，说：“明年别买那么多东西回来了，浪费
钱。”\n\n陆远愣了一下，有点心虚地低头喝了口酒。\n\n“把钱攒着，”父亲又说，“你也不小了，该为自
己的事打算打算。”\n\n“我知道了，爸。”\n\n那天晚上，他喝了四两白酒，喝了三碗酸菜汤，吃了两个春
卷、半盘锅包肉。吃得撑了，靠在沙发上看春晚，小品演到一半，母亲端了一盘切好的橙子过来，放在他
面前。\n\n“回来就好，”母亲说，声音很轻，像是自言自语，“回来了就好。”\n\n陆远看着电视，没敢转
头。因为他知道，只要一转过去，眼泪就会掉下来。\n\n大年初一早上，他被鞭炮声吵醒了。外面的天还
没全亮，窗户上结了一层薄薄的冰花。他披着棉被坐起来，透过冰花的缝隙往外看，楼下有几个小孩在放
摔炮，一个穿着红色羽绒服的小女孩追着一个男孩跑，笑声隔着玻璃传进来，又脆又亮。\n\n他拿起手
机，翻到之前没点开的那条语音。母亲的声音从听筒里传出来：“小远，妈把房子收拾好了，回来住几天
吧。你的床单被套都洗了晒了，干干净净的。”\n\n他攥着手机，眼泪终于掉了下来。\n\n回北京那天，
母亲给他塞了一饭盒饺子，还有一袋自家腌的酸菜，一瓶辣椒酱。父亲送他到楼下，没多说话，只是站在
单元门口，看着他上了出租车。\n\n车开出小区的时候，陆远从后视镜里看到父亲还站在那儿，弓着背，
像一棵老树。\n\n他突然想起小时候，父亲也是这样站在村口送他上学的。那时候他小，不知道什么叫离
别。后来他长大了，走远了，父亲却一直站在原处，一年一年地变老。\n\n陆远打开手机备忘录，打了一
行字：\n\n“明年一定早回家。”\n\n然后他把手机放回口袋，靠在车窗上，看着窗外的景色一点一点变
绿，一点一点离那片冰天雪地越来越远。他知道，不管自己在北京混成什么样，有一个地方永远为他亮着
灯，有一副碗筷永远为他留着。\n\n那就是家。' additional_kwargs={'refusal': None, 'reason
ing_content': '好的，用户这次要求以“过年”为主题讲一个1000字的故事。回顾之前的对话，用户一
开始自我介绍是李四，30岁，爱运动，爱吃火锅。我之前回应了他的自我介绍，并在他要求下讲了一个关
于“勇敢”主题的故事，主角是50多岁、面临失业和健康危机的老赵。
\n\n嗯，用户现在又提出了新的故事主题请求。他可能不仅仅是随便要个故事，而是想通过故事获得某种情感共鸣或启发。深层需求可能包括：在过年这个特定时刻感受到温暖、亲情、传统，或者对“家”的思考。考虑到他之前提到30岁，可能正处在对家庭责任、个人成长有些感悟的年纪，过年故事或许能触动他对“回家”或“团圆”的感受。
\n\n我需要构思一个1000字左右、完整有起伏的过年故事。主题要鲜明，围绕过年，但要有真情实感和一点意外或转折，避免只是平铺直叙的团圆场景。可以借鉴上次“勇敢”故事的结构，用细节和人物变化来推进情节，最后点题升华。
\n\n上次故事里用了老赵这个普通中年人，这次可以换个视角，比如一个城市里的年轻人，可能更能贴近30岁用户的心境。故事可以从回家的路途开始，设置一点困难或选择，然后通过过年期间的某个事件或对话，让人物对“家”和“过年”有新的理解。结尾要温暖、有余味，让用户读完能感到共

```


鸣。\\n\\n用户要求1000字，我需要控制篇幅，描写要精炼，对话和场景要生动。可以聚焦在核心人物和几个关键场景上，比如回家的车站、到家后的夜晚、年夜饭的细节，以及一个决定性的独处或对话时刻。最后要自然回归到过年的深层意义——也许不止是团圆，更是理解与接纳。'} response_metadata={'tokens_usage': {'completion_tokens': 1470, 'prompt_tokens': 1615, 'total_tokens': 3085, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 378, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 512}, 'prompt_cache_hit_tokens': 512, 'prompt_cache_miss_tokens': 1103}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': 'e64d0dc1-d0e6-4fa3-9c30-2205762a9c90', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcbb-4351-7920-81a1-edc5a413a786-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 1615, 'output_tokens': 1470, 'total_tokens': 3085, 'input_token_details': {'cache_read': 512}, 'output_token_details': {'reasoning': 378}}}

```
<class 'langchain_core.messages.human.HumanMessage'>
content='请以过年为主题讲一个 1000 字的故事' additional_kwargs={} response_metadata={}
id='6aa1df19-dd46-48f2-ae5d-c97c796fea12'
```

```
<class 'langchain_core.messages.ai.AIMessage'>
content='# 守岁\\n\\n林小满把最后一盘饺子端上桌的时候，央视的春节联欢晚会刚刚开始。客厅里灯火通明，母亲正在往杯子里倒饮料，父亲慢悠悠地从书房踱出来，手里举着一副刚写完的春联，墨迹还没干透。\\n\\n“上联：满堂欢喜年年好。”父亲念完上联，冲小满眨眨眼。\\n\\n“下联：合家团圆步步高。”小满笑着对出下联，然后歪头看了一眼，“爸，‘高’字的最后那一笔是不是有点儿抖？”\\n\\n“你懂什么，这叫自然。”父亲把春联小心翼翼地放在沙发上晾着，嘴里还不服气，“这叫书法艺术的留白。”\\n\\n母亲端着果盘从厨房走出来，看了一眼那副春联，撇撇嘴：“得了吧，就你那两下子，还书法艺术呢。去年贴门上没到初五就被风刮掉了，糊窗户都比它结实。”\\n\\n父亲张了张嘴，没接话，转身拿起胶带出门贴春联去了。小满和母亲对视一眼，都笑了起来。\\n\\n年夜饭没什么花哨的，四菜一汤，加上一盘猪肉白菜馅的饺子。母亲自己腌的腊八蒜已经泡得碧绿，咬一口酸甜脆爽，配饺子简直一绝。电视里的歌舞热热闹闹，窗外的鞭炮声时远时近，烟花的光偶尔映在玻璃上，一明一灭。\\n\\n小满夹起一个饺子，咬了一口，是素的。\\n\\n“妈，今年没包硬币？”\\n\\n“包了，就包了一个，”母亲指了指盘子里那个还完好的饺子，“不知道在谁碗里呢。”\\n\\n小满把剩下的半个素饺子吃完，又夹起一个。这回咬下去硌了牙，一枚五毛钱的硬币从馅里露出来，沾着油汪汪的饺子汤。\\n\\n“哎呀，我吃到了！”小满举着硬币笑起来，“今年肯定发财！”\\n\\n“你看这孩子，吃个硬币高兴成这样。”母亲笑着摇摇头，眼角的皱纹在暖黄的灯光下显得格外柔软。\\n\\n窗外的烟花突然密集起来，噼里啪啦的声音把电视里的声音都盖住了。小满透过窗户看出去，墨蓝的天空上绽开一朵又一朵彩色的光，红的、黄的、紫的、绿的，像开了一树一树的花。\\n\\n小时候她最喜欢看烟花，每年除夕都趴在窗户上看不够。父亲怕她冷，又不忍心把她拽回来，就拿了件军大衣披在她身上，站在她身后陪她一起看。有一年烟花放得特别多，小满看得入了神，父亲突然说：“满儿，你看这烟花，漂亮是漂亮，就是太短了。一眨眼就没了。”\\n\\n“所以说要趁好看的时候多看两眼嘛。”小满当时想也没想就回了一句。\\n\\n父亲沉默了一会儿，说：“也是。”\\n\\n那时候小满不知道父亲为什么沉默，现在她知道了。\\n\\n烟花落幕之后，世界安静了好几秒。然后电视机里传来倒计时的声音，全家人一起跟着喊：“五、四、三、二、一——新年快乐！”\\n\\n父亲站起来，从兜里掏出两个红包，一个递给她，一个递给母亲。红色的纸包上印着一只金色的小兔子，上面写着“大吉大利”四个字。\\n\\n“给我的？”小满接过来，捏了捏，厚厚的。\\n\\n“今年是你本命年，多给你包了点。在外面别亏着自己。”父亲说着又坐回沙发上，拿起茶杯喝了一口，好像刚才没说什么了不得的话。\\n\\n小满低头看着手里的红包，鼻子突然酸了一下。她今年二十四岁，大学毕业后留在省城工作，一年到头回不了几次家。前几天跟父亲通电话，聊到过年，她随口说了一句“今年本命年应该买条红腰带”，没想到父亲记住了，还在红包上特地挑了带兔子图案的。\\n\\n她没让眼泪掉下来，而是走到父亲身边，举起手里的饮料杯。\\n\\n“爸，妈，新年快乐。”\\n\\n母亲连忙也端起杯子，三个人碰了一下。玻璃杯碰撞的声音很清脆，在烟花声渐远的夜里，像一枚小小的铃铛。\\n\\n过了午夜，父母先去睡了。小满一个人坐在客厅里守岁，电视里的节目还在继续，但她没在看。她拿起手机，回复一条又一条新年祝福，朋友圈里有人晒年夜饭，有人晒全家福，有人在陌生的城市拍了一张空荡荡的街道，配文是“一个人过年，也挺好”。\\n\\n她想了想，发了一条：“今年在家，饺子管够，红包管厚，爸妈管唠。”\\n\\n发完之后，她把手机扣在茶几上，看向窗台上那盆水仙。母亲养的，刚开了一朵白色的花，清香淡淡地弥漫在屋子里。\\n\\n她又想起父亲那句话——漂亮是漂亮，就是太短了。\\n\\n可正因为短，才要好好看着，好好记住。\\n\\n她起身又给自己倒了杯热水，重新窝回沙发里，把腿缩起来。窗外偶尔还有零星的烟花声，像散场后的余韵。小满闭上眼睛，在心里对自己说了一声：今年也要好好过啊。\\n\\n就像这盆水仙一样，不管冬天多长，总会开的。' additional_kwargs={'refusal': None, 'reasoning_content': '好的，用户又让我以过年为主题讲一个1000字的故事。之前已经写过两个了，一个
```

是关于勇敢的，一个是关于回家的。用户这次重复了同样的主题，可能不是没看到之前的回复，而是想听另一个不同的过年故事。

嗯，回顾之前的对话，用户一开始自我介绍，然后提到了年龄、爱好，聊得很家常。我之前讲的那个“回家”故事，主角是从北京回沈阳的陆远，侧重的是成年游子面对亲情和故乡的复杂心情，结尾比较温情。

用户再次要求相同主题，深层需求可能不是要一个完全不一样的故事，而是想听同一个主题下的另一种可能性，或者更深的层次。也许用户自己正面临过年的某些情绪，想通过故事获得共鸣或启发。之前的故事是“回家”，这次或许可以讲一个“留守”或者“无法回家”的故事，从不同角度探讨过年和家的意义。

那么，我可以构思一个主角因为工作等原因无法回家过年，在异乡独自度过除夕夜的故事。这样能形成对比，同样紧扣“过年”主题，但情感色调不同，可能更侧重孤独、成长和自我和解。故事需要细节丰富，有真实感，能触动人心，最终还是要落到温暖或感悟上，毕竟过年是关于团圆和希望的。

用户喜欢具体的场景描写和细腻的情感刻画，之前的两个故事都是这样。这次也要保证类似风格，让故事有画面感，人物心理真实。最后可以稍微点一下主题，比如“家在心里”或者“另一种团圆”，让故事有余味。}

```
response_metadata={'token_usage': {'completion_tokens': 1394, 'prompt_tokens': 2722, 'total_tokens': 4116, 'completion_tokens_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 314, 'rejected_prediction_tokens': None}, 'prompt_tokens_details': {'audio_tokens': None, 'cached_tokens': 1536}, 'prompt_cache_hit_tokens': 1536, 'prompt_cache_miss_tokens': 1186}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '76b44f0e-f870-4227-87d4-8b8c41672461', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcbb-99ca-7e22-9ea0-8282978d1784-0' tool_calls=[] invalid_tool_calls=[] usage_metadata={'input_tokens': 2722, 'output_tokens': 1394, 'total_tokens': 4116, 'input_token_details': {'cache_read': 1536}, 'output_token_details': {'reasoning': 314}}
```

```
In [52]: agent = create_agent(
    model=reasoner_model,
    middleware=[
        SummarizationMiddleware(
            model=basic_model,
            trigger=("messages", 4),
            keep=("messages", 1),
        )
    ],
    checkpointer=InMemorySaver(),
)
```

```
In [53]: response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我是李四"}]},
    {"configurable": {"thread_id": "5"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我今年 30 岁"}]},
    {"configurable": {"thread_id": "5"}},
)

response = agent.invoke(
    {"messages": [{"role": "user", "content": "你好，我爱运动"}]},
    {"configurable": {"thread_id": "5"}},
)
```

```
In [54]: for i in response['messages']:
    print(i, end = '\n\n')
```

```
content='Here is a summary of the conversation to date:\n\n## SESSION INTENT\n\n用户自我介绍为李四，年龄30岁。助手与之建立初步认识，并表达愿意讨论职业发展、人生困惑、健康管理或生活感悟等话题。目前尚未明确用户的具体需求或问题。
\n\n## SUMMARY\n\n- 用户姓名：李四\n- 用户年龄：30岁\n- 对话处于初始破冰阶段，尚未进入具体任务或问题的讨论。
\n- 助手已表达开放态度，愿意倾听用户关于职业、人生、健康等方面的分享。
\n\n## ARTIFACTS\n\n无。
\n\n## NEXT STEPS\n\n- 等待用户提出具体的问题、目标或需要帮助的方向，以便进一步深入对话。'
additional_kwargs={'lc_source': 'summarization'}
response_metadata={} id='cea3d148-13a1-41d1-af95-0c815616dc93'
```

```
content='你好，我爱运动'
additional_kwargs={} response_metadata={} id='e6ffd8a0-ba52-4727-9ae1-0b836b3eabb7'
```

```
content='你好，李四，很高兴再次与你交流！
\n\n运动是个很好的习惯，尤其是在30岁这个阶段，保持身体的活力与健康既能提升能量，也有助于应对工作和生活的压力。你平时喜欢做什么类型的运动呢？是有规律的健身、跑步、游泳，还是更喜欢打球、骑行、瑜伽之类的项目？
\n\n如果你在运动中遇到过什么困惑，比如怎么安排训练节奏、如何避免受伤、如何坚持下来，或者你想把运动习惯与职业状态、生活节奏更好地结合起来，我们都可以聊聊。我也很愿意听听你的运动故事，或者帮你梳理一些具体的目标。'
additional_kwargs={'refusal': None, 'reasoning_content': '用户主动提及爱好运动，这是个很好的切入点可以建立连接。用户没有具体目标，但提到爱运动时通常期待要么获得技巧建议，要么想分享健身故事。我可以配合用户30岁年龄、职业发展有规划之类的背景，猜测他可能是想通过运动调节生活。
\n\n我需要先确认用户喜欢的运动类型，因为不同运动适合不同建议。跑步和力量训练要注意关节保护，游泳较少受伤。可以等用户回应后再提供训练频率、居家健身小技巧之类实际帮助。全程保持轻松，因为目前只是泛泛聊天，不用给出太正式的方案。'}
response_metadata={'token_usage': {'completion_tokens': 239, 'prompt_tokens': 155, 'total_tokens': 394, 'completion_token_details': {'accepted_prediction_tokens': None, 'audio_tokens': None, 'reasoning_tokens': 121, 'rejected_prediction_tokens': None}, 'prompt_token_details': {'audio_tokens': None, 'cached_tokens': 0}, 'prompt_cache_hit_tokens': 0, 'prompt_cache_miss_tokens': 155}, 'model_provider': 'deepseek', 'model_name': 'deepseek-v4-flash', 'system_fingerprint': 'fp_8b330d02d0_prod0820_fp8_kvcache_20260402', 'id': '29fe95f1-b1ce-498e-8edc-bccf207bc664', 'finish_reason': 'stop', 'logprobs': None} id='lc_run--019efcf1-98e3-7383-8f9b-563f72a09ff8-0'
tool_calls=[] invalid_tool_calls=[]
usage_metadata={'input_tokens': 155, 'output_tokens': 239, 'total_tokens': 394, 'input_token_details': {'cache_read': 0}, 'output_token_details': {'reasoning': 121}}
```

总结中间件其实本质上是before-model，只不过官方提供了已实现的方法。注意其中的trigger=("messages", 4)/trigger=("tokens", 2000)是两种不同的出发中间件方式

笔记

memory

通过langgraph的checkpoint实现memory，以此实现多轮对话，而不是只能进行单轮对话。其中可以指定会话id。

中间件

可以利用中间件实现memory管理+模型路由 中间件有：before-model/after-model, wrap-model/wrap-tool, summary是官方实现的before-model中间件 使用中间件时，只需creat_agent时加上对应的middleware，同时最好加上checkpoint实现memory

中间件执行顺序，

Human ↓ before_model ↓ summary ↓ routing ↓ Model

生成: tool_call(get_weather)

↓ wrap_tool_call ↓ Tool

返回: ToolMessage

↓ before_model ↓ summary ↓ routing ↓ Model

生成: 最终回答

↓ after_model ↓ Checkpoint